



PROCESSAMENTO DE LINGUAGEM NATURAL — AVALIAÇÃO FINAL

# O que as reclamações dizem sobre a Latam Airlines

*Pré-processamento, representações textuais (BoW × BERT) e classificação de severidade aplicados a 5.510 reclamações registradas em 2024 no Consumidor.gov.br*

Camille Porto de Sousa

# Por que a Latam? E por que isso importa?



## Pergunta de pesquisa

- **O que os consumidores reclamam sobre a Latam Airlines?**
- Como diferentes representações textuais (BoW vs. embeddings BERT) ajudam — ou não — a entender essas reclamações?
- É possível propor graus de severidade a partir dessas representações?

## O dataset em números

**204.031**

registros totais  
(2022–2024)

**81.206**

reclamações em 2024  
(todas as empresas)

**925**


empresas distintas  
em 2024

**5.510**

reclamações da Latam  
em 2024 (1ª colocada)

*Empresa escolhida: LATAM AIRLINES (TAM) — recorte exclusivo de 2024 (jan–dez), critério ≥500 reclamações atendido.*



# Latam Airlines lidera o ranking de reclamações em 2024



## Top 10 empresas — 2024

- Latam acumula 5.510 reclamações em 2024 — a maior base entre as 925 empresas registradas.
- Setor aéreo (Latam + Gol) e turismo (Hurb) dominam o topo, indicando insatisfação concentrada em viagens.
- Volume robusto garante representatividade estatística acima do mínimo exigido ( $\geq 500$ ).

# Volume constante, nota predominante 1 e maioria 'Resolvido'



- Sazonalidade leve, com pico em abril (período de alta de viagens) e queda no fim do ano.
- Nota 1 (insatisfação máxima) é amplamente dominante — sinaliza que o canal é usado majoritariamente para frustração extrema, não feedback neutro.
- 85,7% das reclamações aparecem como 'Resolvido' no status formal — mas, como veremos, o conteúdo textual revela insatisfação que a etiqueta de status não captura.

# A limpeza reduz o texto à metade — e muda o que se compara



## Pipeline de limpeza aplicado

- Minúsculas + remoção de acentos
- Remoção de URLs, e-mails e números isolados
- Remoção de pontuação e caracteres especiais
- Tokenização (NLTK, pt-BR)
- Remoção de stopwords (NLTK + lista customizada: 'empresa', 'produto', 'cliente'...)
- Stemming opcional (RSLP) e remoção de tokens curtos (<3 letras)

### Original:

"Empresa NUNCA responde! Fui cobrado R\$150,00 indevidamente em 15/03/2024..."

### Limpo:

"nunca responde cobrado indevidamente acesse"

# 49,0%

redução média de tokens após a limpeza  
(166,9 → 84,2 tokens, em média, por reclamação)

## Impacto observado nos resultados

- Textos ficam mais curtos e densos — focados em substantivos/verbos relevantes (overbooking, bagagem, reembolso).
- Reduz ruído para BoW: vocabulário menor, similaridades mais interpretáveis.
- Para BERT, a limpeza é menos crítica — o modelo já lida bem com texto cru, pois aprende contexto e morfologia.
- Distribuição de tamanho desloca-se visivelmente para a esquerda (histograma 'Original' vs 'Limpo').

# O que se perde ao normalizar o texto?

4.501

Números removidos  
(valores, datas, CPFs, protocolos) —  
só nas primeiras 500 reclamações

6

URLs removidas  
(links para evidências/prints)

8

E-mails removidos  
(contatos de suporte)

248

Marcas de pontuação  
(!/? ) removidas — perde-se ênfase  
emocional

## Perdas qualitativas — as mais críticas para a interpretação

- Negação ('não' / 'nao'): a remoção de acentos uniformiza variantes, mas se 'não' for tratado como stopword, o sentido da frase pode se INVERTER.
- Stemming: 'cobrança', 'cobrado' e 'cobrar' tornam-se a mesma raiz — bom para agrupar temas, mas perde tempo verbal e número (singular/plural).
- Maiúsculas: ênfase do consumidor ('NUNCA', 'URGENTE') se perde ao normalizar para minúsculas — sinal de severidade emocional descartado.
- Valores monetários e datas podem indicar o tamanho do prejuízo e o tempo de espera — informação relevante para priorização que a limpeza descarta.

# Duas formas de 'enxergar' o texto: contagem vs. contexto



## Bag of Words (BoW)

*CountVectorizer + similaridade do cosseno*

- Representa cada reclamação como um vetor de frequência de palavras.
- Matriz gerada: 600 reclamações × 7.585 termos.
- Similaridade depende de palavras EXATAS em comum — sinônimos não são reconhecidos.
- No exemplo testado, a reclamação mais semelhante teve score 0,50 — bem mais baixo que o BERT.

*t-SNE dos vetores BoW: pontos espalhados de forma quase uniforme — sem agrupamentos visuais claros.*



## BERT (embeddings contextuais)

*neuralmind/bert-base-portuguese-cased + similaridade do cosseno*

- Representa cada reclamação como um vetor denso de 768 dimensões (média dos embeddings de token).
- Captura significado e contexto — entende sinônimos e paráfrases.
- Similaridades muito mais altas e consistentes (ex.: 0,85, 0,84, 0,84, 0,84, 0,83).
- Reclamações sobre bagagem danificada, milhas bloqueadas e remarcação de voo aparecem como mais próximas entre si.

*t-SNE dos embeddings BERT: formam-se regiões/aglomerados mais definidos — reforçado depois pelo K-Means.*

# Mesma reclamação, dois rankings de similaridade diferentes

**Reclamação-base:** "...voo GRU-MOC...overbooking...solicitei preterimento de embarque...travel voucher..."

### TOP-5 mais semelhantes — Bag of Words

**0,50** Bagagem danificada em viagem a Santiago (Chile)

**0,31** Atraso de voo BCN-GRU, realocação

**0,24** Comprovante de embarque não fornecido

**0,23** Mudança de portão / descontentamento com voo

**0,21** Voo Manaus-São Paulo alterado pela Latam

### TOP-5 mais semelhantes — BERT

**0,85** Bagagem danificada em viagem a Santiago (Chile)

**0,84** Bloqueio de milhas / dificuldade de resgate de pontos

**0,84** Bagagem danificada em trecho Nova York-São Paulo

**0,84** Remarcação de passagens, código de reserva citado

**0,83** Cancelamento por motivo de consulta médica

*Ambos concordam no item mais próximo (bagagem danificada) — mas o BERT mantém scores altos e consistentes (0,83–0,85) para reclamações tematicamente relacionadas mesmo sem sobreposição forte de palavras, enquanto o BoW cai rapidamente (0,50 → 0,21) e depende de termos literalmente repetidos.*




## BERT revela estrutura onde o BoW vê apenas ruído

t-SNE — Bag of Words



t-SNE — BERT + K-Means (3 clusters)



Mesmo conjunto de reclamações, duas geometrias diferentes: BoW não separa por significado; BERT projeta reclamações semanticamente próximas em regiões vizinhas, permitindo agrupamento via K-Means.

### 3. GRAUS DE SEVERIDADE

## Três clusters, três graus de severidade

Metodologia: embeddings BERT → K-Means ( $k=3$ ) → leitura qualitativa de 10 exemplos por cluster → rótulo de severidade atribuído por cluster.



### Leve

104 reclamações

*Cancelamentos, reembolsos e alterações de voo tratados de forma administrativa.*

- Cancelamento de passagem
- Pedido de reembolso simples
- Alteração de voo
- Solicitação de documentos



### Moderada

285 reclamações

*Prejuízo financeiro e transtorno significativo, mas pontual.*

- Overbooking
- Cobrança indevida de bagagem
- Bagagem avariada
- Dificuldade de atendimento
- Bloqueio de milhas



### Grave


211 reclamações

*Relatos longos, com múltiplos transtornos e grandes prejuízos.*

- Passageiro com necessidades especiais prejudicado
- Perda de viagem internacional
- Extravio de bagagem
- Cancelamento sem assistência
- Reembolsos de altos valores

### 3. GRAUS DE SEVERIDADE — DISTRIBUIÇÃO

Quase a metade das reclamações é 'Moderada'; 1 em cada 3 é 'Grave'



**52%**

das reclamações analisadas são Moderadas ou Graves — prejuízo real e recorrente

**600**

reclamações processadas via embeddings BERT (subconjunto do total de 5.510)

**17%**

são Leves — questões administrativas resolvíveis sem grande esforço

# Respostas às perguntas-chave do seminário

**Qual representação funcionou melhor?**

BERT. Capturou similaridade semântica mesmo sem repetição literal de palavras (scores 0,83–0,85 vs. 0,21–0,50 do BoW) e gerou agrupamentos visualmente coerentes no t-SNE.

**O pré-processamento alterou os resultados?**

Sim — reduziu o texto em ~49% e tornou o BoW mais limpo/interpretável. Para o BERT o efeito é menor, mas a limpeza ainda ajuda a remover ruído irrelevante (links, e-mails, dados pessoais).

**Modelos contextuais trouxeram vantagens?**

Sim. BERT entende sinônimos, paráfrases e contexto, algo que o BoW (baseado em contagem de palavras exatas) não consegue. Isso se refletiu em agrupamentos mais nítidos no K-Means.

**Reclamações graves têm características linguísticas próprias?**

Sim — relatos mais longos, com mais detalhes (datas, valores, protocolos), menção a vulnerabilidade (idade, saúde, deficiência) e linguagem de urgência ('URGENTE', 'praticamente impossível').

**Quais limitações foram encontradas?**

Amostra de 600 reclamações para BERT (custo computacional); rótulos de severidade definidos por leitura qualitativa dos clusters (não há ground truth); stopwords podem remover negações relevantes; CountVectorizer sensível a vocabulário, sem normalização TF-IDF.



## Conclusão

**BERT entrega representações mais ricas para entender reclamações reais — mas a leitura humana ainda é essencial para validar os clusters e definir critérios de severidade.**